

Projet de statistique appliquée

**ESTIMATION DU PARAMÈTRE DE
HURST DANS LES MODÈLES DE
VOLATILITÉ RUGUEUSE**

Maxime FACON Adrien MATHIEU Axel PINÇON David PREMACHANDRA



Encadré par M. Marc Hoffmann

2A ENSAE

2023-2024

Résumé

Durant ce projet, nous avons tâché d'estimer, via différentes méthodes statistiques, le paramètre de Hurst du processus de volatilité.

Remerciements

Nous remercions chaleureusement Pr. Marc Hoffman, qui a accepté de nous superviser sur ce projet, qui nous a ouvert les portes de l'Université Paris Dauphine, et qui nous a transmis son grand intérêt pour les modèles de volatilité rugueuse.

Nous remercions de plus Grégoire Szymanski, dont l'aide a été précieuse afin d'optimiser nos différents algorithmes, et qui a eu la gentillesse de nous donner accès à la base de données de volatilité de l'*Oxford Man Institute*.

Pour finir, nous remercions l'ENSAE, qui permet à ses étudiants de réaliser ces projets de statistiques appliquées.

Table des matières

1	Introduction	3
2	Définition de la volatilité	4
2.1	La volatilité réalisée	4
2.2	La volatilité implicite	4
3	Évolution des modèles dans la littérature	5
3.1	Volatility is constant : Le modèle de Black-Scholes	5
3.2	Volatility is local : Le modèle de Dupire	7
3.3	Volatility is stochastic : Le modèle de Hull et White	7
3.4	Volatility is fractional : Le modèle de Comte et Renault	8
3.5	Volatility is rough : Le modèle de Rosenbaum et al.[8]	10
4	Étude statistique et estimations	12
4.1	Présentation des données	12
4.1.1	Quasi-gaussianité des $\log(\sigma_{t+1}) - \log(\sigma_t)$	12
4.1.2	Processus de volatilité	13
4.2	Estimation de H par la méthode [15]	13
4.2.1	Présentation du modèle	13
4.2.2	Mise en place de l'algorithme	14
4.2.3	Présentation des données simulées :	15
4.2.4	Présentation des résultats sur données simulées de prix : . . .	16
4.2.5	Présentation des résultats sur données simulées de volatilité : .	16
4.2.6	Mise en perspective des résultats	17
4.3	Estimation de H par la méthode [8]	17
4.3.1	Mise en place expérimentale	18
4.3.2	Présentation des résultats sur des données simulées de volatilité	18
4.3.3	Présentation des résultats sur des données réelles de volatilité intégrée (base Oxford)	19
4.3.4	Présentation des résultats sur des données réelles de prix . . .	20
5	Conclusion	22
6	Appendice	23
6.1	Cadre mathématique	23
6.2	Dynamiques de prix et de volatilité simulées	25
6.3	Histogramme de $\widehat{H}$ pour des valeurs de volatilité simulées dans le modèle[15]	26
6.4	Construction des proxy de volatilité	26
6.4.1	Modèle de Parkinson (1976)	27
6.4.2	Modèle de Garman-Klass (1980)	27
6.4.3	Modèle de Rogers-Satchell-Yoon (1991)	28
	Bibliographie	29

1 Introduction

Grâce aux travaux de 1973 de Black, Scholes and Merton, nous sommes en capacité d'exprimer, du moins formellement, le prix d'une option européenne sur un sous-jacent, avec quelques hypothèses. L'hypothèse importante de ce modèle est le fait que la volatilité est supposée constante au cours du temps. Cependant, diverses simulations numériques ont montré que ce terme n'était en réalité pas constant. Afin de rendre compte de manière plus précise de la dynamique d'actifs risqués, il était nécessaire de développer le modèle de Black-Scholes. Ceci a donné lieu aux modèles de volatilité stochastique

Au lieu de considérer que la volatilité est constante, nous allons supposer qu'elle varie au cours du temps, et que sa dynamique est celle d'un processus d'Itô. Cependant, malgré les différents modèles de volatilité stochastique produits (notamment le modèle d'Heston), certaines spécificités intrinsèques aux propriétés empiriques de la volatilité ne sont pas retranscrites. Il a donc fallu développer à nouveau ces modèles.

C'est en 2014, que Jim Gatheral, Thibault Jaisson ainsi que Mathieu Rosenbaum ont présenté leur article *Volatility is rough*[8], où ils montrent, par analyse statistique sur des données de prix, que le terme de volatilité ne suit pas une dynamique dictée par un mouvement brownien standard, mais par un mouvement brownien fractionnaire, de paramètre de Hurst H de l'ordre de 0.1, ce qui a donné lieu à un nouveau paradigme : les modèles de volatilité rugueuse.

Dès lors, les modèles de volatilité rugueuse se sont développés (avec par exemple le modèle rough Heston), et il a été question de quantifier précisément le paramètre de Hurst H qui apparaît dans la dynamique de la volatilité.

Tout l'intérêt de notre projet de statistique appliquée réside dans l'étude et l'implémentation de diverses méthodes, de plus en plus sophistiquées, visant à estimer ce paramètre via des données de prix.

Pour la définition des outils mathématiques utilisés durant ce mémoire, se référer à 6.1.

2 Définition de la volatilité

Dans le contexte financier, la volatilité d'un actif représente une mesure statistique de la dispersion de ses rendements sur une période donnée. En réalité, deux types de volatilité co-existent : la volatilité réalisée ou intégrée et la volatilité implicite.

2.1 La volatilité réalisée

La volatilité réalisée est définie comme l'écart-type des rendements logarithmiques d'un actif sur une période historique donnée. Sa valeur est, par construction, dépendante de la taille de la fenêtre temporelle ainsi que de la granularité des données utilisées. Par exemple, une fenêtre plus large peut lisser des variations de prix extrêmes, tandis qu'une granularité plus fine (comme des données intrajournalières) peut révéler des variations de prix invisibles dans des données journalières.

La volatilité réalisée est une mesure a posteriori, c'est-à-dire qu'elle est calculée à partir des données historiques et ne reflète pas la volatilité instantanée ou future de l'actif. Voici deux formules communément utilisées pour la calculer :

— **Volatilité annuelle :**

$$\sigma_{\text{annuelle}} = \sqrt{\frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2}$$

où $X_i := \log(\frac{S_i}{S_{i-1}})$ (S_i , prix de l'actif au temps i) représente le rendement logarithmique au temps i , $\bar{X}$ est la moyenne des rendements logarithmiques, et N est le nombre total de points de données dans l'année.

— **Volatilité sur une fenêtre glissante :**

$$\sigma_{t,h} = \sqrt{\frac{1}{2h+1} \sum_{i=t-h}^{t+h} (X_i - \bar{X}_{t,h})^2}$$

où h est la demi-taille de la fenêtre autour du temps t , et $\bar{X}_{t,h}$ est la moyenne des rendements dans la fenêtre.

2.2 La volatilité implicite

La volatilité implicite est un indicateur du sentiment de marché, elle traduit les anticipations des acteurs du marché sur les variations de l'actif à venir. Contrairement à la volatilité réalisée qui est dérivée de données historiques de l'actif, la volatilité implicite est extraite du prix des options ou d'autres instruments financiers dérivés, desquelles l'actif en est le sous-jacent.

La volatilité implicite s'obtient en inversant un modèle de tarification d'options, tel que le modèle de Black-Scholes (nous reviendrons dessus dans la section 2.1).

Exemple 2.1. *Considérons un modèle financier $\mathcal{M}$ qui permet de pricer des options call européennes en fonction de paramètres tels que la maturité T , le strike K , l'actif sous-jacent A , et sa volatilité σ_t . Si le prix de marché de l'option à l'instant t est noté S_t , et en supposant que le marché est efficace, alors $S_t = C_{\mathcal{M},t}(T, K, A, \sigma_t)$. En inversant cette relation, nous obtenons la volatilité implicite comme suit :*

$$\sigma_t = C_{\mathcal{M},t}^{-1}(S_t).$$

Par construction, la volatilité implicite est dépendante du modèle d'évaluation d'options utilisé. En effet, si les conditions de marché ne correspondent pas à celles retenues dans les modèles, elle ne pourra être en mesure de rendre compte de la réalité.

Les deux mesures de volatilité présentées ci-dessus ne coïncident généralement pas. La volatilité réalisée peut indiquer comment l'actif s'est comporté dans le passé, tandis que la volatilité implicite offre un aperçu de la manière dont les investisseurs anticipent le comportement de l'actif. Cela rend la volatilité implicite particulièrement utile pour la gestion du risque et la stratégie de couverture dans des environnements de marché dynamiques.

3 Évolution des modèles dans la littérature

3.1 Volatility is constant : Le modèle de Black-Scholes

Le modèle de Black-Scholes[11] est l'un des modèles les plus utilisés dans le monde de la finance. Il repose sur certaines hypothèses dont les plus notables sont l'absence d'opportunité d'arbitrage, l'absence de coût de transaction, l'existence d'un actif sans risque dont le prix évolue à un taux d'intérêt r fixe.

En notant S_t^0 le prix de l'actif sans risque au temps $t \geq 0$, on a $S_t^0 = e^{rt}$. De plus, en notant S_t le prix de l'actif risqué du modèle, celui-ci est modélisé comme solution de l'équation différentielle stochastique

$$\frac{dS_t}{S_t} = \mu dt + \sigma dB_t.$$

où $\mu \in \mathbb{R}$ le taux de drift de l'actif, et $\sigma > 0$ est sa volatilité. Notons que dans ce modèle, le drift et la volatilité sont tous les deux supposés constants. Par application de la formule d'Ito, nous trouvons que

$$S_t = S_0 e^{(\mu - \sigma^2/2)t + \sigma B_t}$$

est solution de l'EDS, et donc la solution unique par le théorème d'unicité de la solution. Remarquons que

$$d \log S_t = (\mu - \frac{\sigma^2}{2})dt + \sigma dB_t$$

donc on a bien $\sigma^2 = \frac{d}{dt} \log S_t$.

Intéressons-nous au pricing d'options dans le cadre de ce modèle. Notons tout d'abord qu'en posant

$$Z_t^\lambda := e^{-\lambda B_t - \frac{\lambda^2}{2}t}$$

avec $\lambda \in \mathbb{R}$, alors (Z_t^λ) est une $(\mathcal{F}_t)$ -martingale pour la probabilité $\mathbb{P}$. De plus, nous avons le résultat suivant.

Théorème 3.1. (*Girsanov, version simplifiée*)

Soit $T > 0$. Posons $\mathbb{Q}^\lambda$ définie sur $(\Omega, \mathcal{F}_T)$ définie par

$$\forall A \in \mathcal{F}_T, \mathbb{Q}^\lambda(A) := \mathbb{E}_\mathbb{P}[Z_T^\lambda \mathbf{1}_A].$$

Alors $\mathbb{Q}^\lambda$ est une mesure de probabilité sur $(\Omega, \mathcal{F}_T)$. On a de plus, pour tout $0 \leq t \leq T$:

$$\forall A \in \mathcal{F}_t, \mathbb{Q}^\lambda(A) = \mathbb{E}_\mathbb{P}[Z_T^\lambda \mathbf{1}_A] = \mathbb{E}_\mathbb{P}[Z_t^\lambda \mathbf{1}_A].$$

Enfin posons pour tout $B_t^\lambda := B_t + \lambda t$. Alors $(B_t^\lambda)_{0 \leq t \leq T}$ est un $(\mathcal{F}_t)_{0 \leq t \leq T}$ mouvement brownien sur $(\Omega, \mathcal{F}_T, \mathbb{Q}^\lambda)$.

Remarque. L'égalité $\mathbb{E}_{\mathbb{P}}[Z_T^\lambda \mathbf{1}_A] = \mathbb{E}_{\mathbb{P}}[Z_t^\lambda \mathbf{1}_A]$ pour $t \leq T$ et $A \in \mathcal{F}_t$ est une conséquence directe du fait que (Z_t^λ) soit une martingale pour la probabilité $\mathbb{P}$.

Utilisons ce résultat dans le cadre de notre modèle. Notons $\lambda^* := \frac{\mu-r}{\sigma}$ et $\mathbb{Q}^* := \mathbb{Q}^{\lambda^*}$. Enfin, notons également $B^* := B^{\lambda^*}$ le mouvement brownien associé à cette mesure.

Définition 3.1. (Probabilité risque-neutre)

Une probabilité $\mathbb{Q}$ sur $(\Omega, \mathcal{F}_T)$ est dite être une probabilité risque-neutre si elle est équivalente à $\mathbb{P}$ et si le processus de prix actualisé $(\tilde{S}_t)_{0 \leq t \leq T}$ défini par

$$\tilde{S}_t := e^{-rt} S_t$$

est une martingale sur $(\Omega, (\mathcal{F}_t)_{0 \leq t \leq T}, \mathbb{Q})$.

Proposition 3.1. $\mathbb{Q}^*$ est l'unique probabilité risque-neutre du modèle.

Remarque. Le caractère de martingale de $\tilde{S}$ sous $\mathbb{Q}^*$ se remarque en voyant que

$$\begin{aligned} d\tilde{S}_t &= (\mu - r)\tilde{S}_t dt + \sigma \tilde{S}_t dB_t \\ &= \sigma \lambda^* \tilde{S}_t dt + \sigma \tilde{S}_t dB_t \\ &= \sigma \tilde{S}_t d(B_t + \lambda^* t) \\ &= \sigma \tilde{S}_t dB_t^*. \end{aligned}$$

Remarquons également que

$$\frac{dS_t}{S_t} = r dt + \sigma dB_t^*$$

donc la loi de S sous $\mathbb{Q}^*$ ne dépend plus du coefficient de drift μ .

Ce résultat permet de montrer que le modèle vérifie l'absence d'opportunité d'arbitrage. De plus, la probabilité risque-neutre permet alors de pricer les produits dérivés.

Proposition 3.2. Considérons un produit dérivé de l'actif risqué S de maturité T , dont le payoff est modélisé par une variable aléatoire G $\mathcal{F}_T$ -mesurable. Alors le prix p_t^G de ce produit dérivé au temps $\leq t \leq T$ est donné par

$$p_t^G = e^{-r(T-t)} \mathbb{E}_{\mathbb{Q}^*}[G | \mathcal{F}_t].$$

Appliquons ce résultat à une option d'achat européenne de strike $K \geq 0$ et de maturité $T > 0$. Son Notons $C_t(K, T)$ son prix au temps t . Son prix à maturité est donné par son payoff $C_T(K, T) := (S_T - K)_+$.

Proposition 3.3. On a

$$C_t(K, T) = S_t N(d_1) - K e^{-r(T-t)} N(d_2)$$

où N est la fonction de répartition de la loi normale centrée réduite,

$$d_1 := \frac{\log(S_t/K) + (r + \sigma^2/2)(T-t)}{\sigma \sqrt{T-t}}$$

et

$$d_2 := d_1 - \sigma \sqrt{T-t} = \frac{\log(S_t/K) + (r - \sigma^2/2)(T-t)}{\sigma \sqrt{T-t}}.$$

Si on observe le prix de l'option d'achat C_t , le prix du sous-jacent S_t ainsi que le taux d'intérêt r , alors cette formule permet d'impliciter la volatilité σ . Lorsqu'on retrouve σ de cette façon, on appelle la valeur trouvée la volatilité implicite comme expliqué en première partie. Si le modèle de Black-Scholes était réaliste, alors pour des options d'achat de maturité de maturités et/ou de strikes différents, nous devrions impliquer la même valeur de σ car la volatilité du sous-jacent est supposée constante. Or, ceci n'est pas le cas en pratique. En effet, nous observons une dépendance de la volatilité implicite à la fois par rapport au strike K et par rapport à la maturité T . Le graphique de la fonction de volatilité implicite par rapport à la maturité et au strike est appelé la surface de volatilité.

3.2 Volatility is local : Le modèle de Dupire

Le modèle de volatilité locale proposé par Dupire[6] a été proposé par palier au fait que la surface de volatilité implicite trouvée par le prix des options dans le modèle de Black-Scholes ne soit pas consistante avec la modélisation d'une volatilité constante du prix du sous-jacent. En effet, le modèle de Black-Scholes se fonde sur des hypothèses peu réalistes sur la dynamique du prix. En effet, les log-returns $\log(S_{t_2}/S_{t_1})$ pour $t_1 < t_2$ sont normalement distribués dans le modèle de Black-Scholes, ce qui n'est pas vérifié en pratique. Le modèle de volatilité locale consiste à poser une fonction de volatilité locale $\sigma : (t, x) \mapsto \sigma(t, x)$. La dynamique du prix de l'actif risqué est alors modélisée par

$$dS_t = rS_t dt + \sigma(t, S_t) dB_t.$$

Remarquons tout d'abord que le drift de l'actif est égal à taux d'intérêt de l'actif sans risque r . Ceci correspond au fait que nous travaillons dans un cadre risque-neutre. En effet, nous avons vu dans la partie précédente sur le modèle de Black-Scholes que sous la probabilité risque-neutre, le drift du prix de l'actif risqué était r .

Remarquons de plus qu'en choisissant $\sigma(t, x) = \sigma x$ pour $\sigma > 0$ constant, nous retrouvons alors le modèle de Black-Scholes (sous probabilité risque-neutre).

Le choix de la fonction de volatilité locale $\sigma(t, x)$ est déterminant. D'une part elle détermine la distribution qu'aura le processus de prix. D'autre part, il faudrait qu'en pricant des options avec ce modèle et en calculant la volatilité implicite associée, celle-ci devrait être égale au $\sigma(t, S_t)$ associé du modèle. Le processus consistant à calculer une fonction de volatilité locale consistante est appelé la calibration du modèle. Dupire a montré l'existence d'une fonction de volatilité consistante avec les volatilités implicites trouvées par les prix d'un ensemble d'options d'achats. Cette fonction se trouve en résolvant une équation aux dérivées partielles. Cependant, la dynamique du prix associée à cette fonction n'a toujours une distribution correspondant bien à ce qui est observé sur le marché.

3.3 Volatility is stochastic : Le modèle de Hull et White

Une autre façon de palier aux problématiques liées au modèle de Black-Scholes fut le développement de nouveaux modèles dits de volatilité stochastique[10]. Le prix de l'actif risqué est toujours modélisé comme un processus d'Ito de la forme

$$\frac{dS_t}{S_t} = \mu dt + \sigma_t dB_t$$

mais dans ces nouveaux modèles, le processus de volatilité (σ_t) est lui-même stochastique. Contrairement au modèle de volatilité locale, la source d'aléatoire dans la volatilité ne provient plus uniquement de la dépendance au prix de l'actif S_t . Hull et White (1987), Scott (1987), et

Melino et Turnbull (1990) ont proposé le modèle suivant : le prix est un processus d'Ito de la forme

$$\frac{dS_t}{S_t} = \mu dt + \sigma_t dB_t$$

et la volatilité σ est également un processus d'Itô, de la forme

$$d \log \sigma_t = k(\theta - \log \sigma_t)dt + \gamma dW_t.$$

Ici, W est un autre mouvement Brownien, tel que le couple (B, W) est non-dégénéré. W est alors la nouvelle source d'aléatoire déterminant la volatilité.

La forme particulière du processus de volatilité σ_t provient du fait que l'on souhaite retranscrire le phénomène de *mean reversion* que l'on observe empiriquement.

Les méthodes de pricing d'option associées à ce modèle ont permis d'expliquer l'effet de smile de la volatilité observé qui n'était pas expliqué par le modèle de Black-Scholes.

3.4 Volatility is fractional : Le modèle de Comte et Renault

En 1998, Comte et Renault[5] expliquent que ce dernier modèle de volatilité stochastique présenté avait cependant des défauts.

En pratique, le *smile* de volatilité décroît avec la maturité de l'option. Ceci est retranscrit dans le modèle de volatilité stochastique. Cependant, la décroissance est bien plus lente en pratique que dans le modèle. Ce phénomène est appelé la persistance de la volatilité. Ceci mène Comte et Renault à penser que la volatilité doit être modélisée comme un processus à **mémoire longue**, tel que son auto-corrélation est à décroissance lente. Une série temporelle $(X_k)_{k \in \mathbb{Z}}$ stationnaire est dite à mémoire longue si son auto-corrélation absolue $|\rho(X_0, X_k)|$ décroît lentement, au sens où

$$\sum_{k \in \mathbb{Z}} |\rho(X_0, X_k)| = +\infty,$$

où $\rho(X, Y)$ désigne la corrélation entre les variables aléatoires X et Y . Ce concept de mémoire longue se généralise dans le cadre de processus continus, lorsque $|\rho(X_t, X_{t+h})|$ décroît lentement avec h . Pour modéliser de la mémoire longue dans un processus continu, il est possible d'utiliser un mouvement brownien fractionnaire.

Définition 3.2. Soit $H \in (0, 1)$. On dit que W^H est un mouvement Brownien fractionnaire standard d'exposant de Hurst H si c'est un processus gaussien continu, centré, nul en 0, dont la covariance est donnée par

$$\mathbb{E}[W_s^H W_t^H] = \frac{1}{2}(|t|^{2H} + |s|^{2H} - |t - s|^{2H}).$$

Lorsque $H = 1/2$, nous obtenons le mouvement Brownien standard. De plus, il possède les propriétés suivantes.

Proposition 3.4. Le mouvement Brownien fractionnaire est à accroissements stationnaires dans le sens où pour tout $t, \delta \geq 0$

$$W_{t+\delta}^H - W_t^H \stackrel{\mathcal{L}}{=} W_\delta^H.$$

Il vérifie la propriété d'auto-similarité suivante :

$$\forall a > 0, t \geq 0, \quad W_{at}^H \stackrel{\mathcal{L}}{=} a^H W_t^H.$$

De plus, pour tout $0 < h < H$, W^H est presque sûrement h -hölderien.

Le brownien fractionnaire est d'autant plus régulier que H est proche de 1. Il est de plus notamment intéressant pour modéliser la mémoire longue grâce à la propriété suivante :

Proposition 3.5 (Mémoire longue). *Lorsque $H > 1/2$, le processus d'accroissements $\Delta_k^H = W_k^H - W_{k-1}^H$ défini sur $\mathbb{N}^*$ est un processus stationnaire à mémoire longue dans le sens où*

$$\sum_{k \geq 1} \rho(\Delta_1^H, \Delta_k^H) = +\infty.$$

Remarque. *Pour un mouvement Brownien standard ($H = 1/2$), les accroissements sont indépendants donc ne sont pas corrélés.*

Revenons à Comte et Renault, qui cherchaient à modifier le modèle de volatilité stochastique introduit en section précédente afin d'obtenir une volatilité à mémoire longue. Ils décident alors de reprendre ce modèle en changeant le second mouvement brownien associé à la volatilité en un mouvement Brownien fractionnaire d'exposant de Hurst strictement supérieur à $1/2$, qui a alors des incréments soient à mémoire longue. Le modèle devient alors

$$\frac{dS_t}{S_t} = \mu dt + \sigma_t dB_t$$

avec

$$d \log \sigma_t = k(\theta - \log \sigma_t)dt + \gamma dW_t^H.$$

Cela signifie qu'on doit avoir

$$\log \frac{\sigma_t}{\sigma_0} = \int_0^t k(\theta - \log \sigma_s)ds + \gamma W_t^H.$$

Afin de résoudre cette EDS, et de trouver la forme de σ , Comte et Renault définissent les intégrales stochastiques de la forme

$$\int_0^t f(t-s) dW_s^H$$

ce qui n'est pas évident à première vue car W^H n'est pas une semi-martingale. Cette intégrale se définit en utilisant la représentation de Mandelbrot - Van Ness suivante :

Proposition 3.6 (Mandelbrot - Van Ness). *Soit W un mouvement Brownien. Posons*

$$W_t^H := C_H \left(\int_{-\infty}^t \frac{dW_s}{(t-s)^{\frac{1}{2}-H}} - \int_{-\infty}^0 \frac{dW_s}{(-s)^{\frac{1}{2}-H}} \right)$$

où

$$C_H = \sqrt{\frac{2H\Gamma(3/2-H)}{\Gamma(H+1/2)\Gamma(2-2H)}}.$$

Alors W^H est un mouvement Brownien fractionnaire standard d'exposant de Hurst H .

Comte et Renault résolvent alors cette EDS et observent que le processus de volatilité obtenu est bel et bien lui aussi à mémoire longue. C'est alors ce premier modèle qui cherchait à décrire une volatilité à mémoire longue que furent introduit les modèles de volatilité stochastique fractionnaire, que nous allons étudier dans ce mémoire.

3.5 Volatility is rough : Le modèle de Rosenbaum et al.[8]

Les modèles précédents présentaient une limitation significative due à leur fondement sur des données antérieures à l'émergence du trading haute fréquence. Cette lacune devient critique en raison de l'impact croissant du trading haute fréquence sur la dynamique des marchés financiers modernes. Il est donc impératif de reconsidérer les modèles de volatilité à la lumière de ces nouvelles données.

L'objectif principal de l'étude menée par Rosenbaum, Jaisson et Gatheral n'est pas de débattre de la "mémoire" de la volatilité en tant que telle, considérée comme trop fragile pour des analyses incluant des données haute-fréquence. Au contraire, ils cherchent à reproduire fidèlement les caractéristiques des séries temporelles observées de la volatilité sur des échelles de temps allant d'un jour à dix ans.

Pour construire leur modèle, Rosenbaum et ses pairs partent de l'observation que la forme générale de la surface de volatilité 1 tend à rester relativement stable, au moins en première approximation, malgré les fluctuations de niveau et d'orientation.




FIGURE 1 – Surface de volatilité du S&P 500, 20 juin 2013

Cette propriété d'homogénéité temporelle implique que, bien que les conditions de marché puissent varier, les principes sous-jacents régissant la volatilité et son impact sur les prix des options restent constants. Cette hypothèse simplifie considérablement la modélisation mathématique et statistique des marchés d'options, permettant notamment à l'équipe de développer des modèles plus robustes et prédictifs. L'article va donc développer un modèle de volatilité homogène du temps et des prix (*ie.* un processus dont les paramètres sont indépendants du temps et des prix).

Une des motivations de l'équipe a été de remarquer que les modèles conventionnels, bien que homogènes en temps et en prix, présentent des lacunes notables. Par exemple, les modèles de Hull and White, Heston et SABR ne parviennent pas à fitter la surface de volatilité convenablement. En particulier, alors que la réalité des marchés montre que la structure à terme du skew de volatilité à la money (ATM) :

$$\psi(\tau) := \left| \frac{\partial}{\partial k} \sigma_{BS}(k, \tau) \right|_{k=0}$$

est bien approximé par une fonction puissance du temps à échéance, ces modèles tendent à produire une structure à terme constante pour les petits τ (temps jusqu'à échéance) et une

somme d'exponentielles décroissantes pour de plus grands τ .




FIGURE 2 – Les points noirs sont des estimations non paramétriques des skews de volatilité ATM du S&P, 20 juin 2013 ; la courbe rouge est l'approximation par une loi puissance $\psi(\tau) = A\tau^{-0.4}$.

Par ailleurs, les travaux de Fukasawa ont montré qu'un modèle de volatilité stochastique dans lequel la volatilité est régie par un mouvement brownien fractionnaire avec un exposant de Hurst H génère un skew de volatilité à ATM de la forme $\psi(\tau) \sim \tau^{H-\frac{1}{2}}$, du moins pour les petits τ . L'aspect crucial ici est que pour qu'un modèle de ce type génère une surface de volatilité d'une forme raisonnable, il est nécessaire d'avoir une valeur de H proche de zéro (autour de 0.1 si l'on prend l'exemple de 2).

Les auteurs modélisent le processus de volatilité $(\sigma_t)_{t \geq 0}$ comme étant une transformation continue d'un processus $(Z_t^H)_{t \geq 0}$ satisfaisant l'EDS suivante :

$$dZ_t^H = \nu dW_t^H - \alpha(Z_t^H - m)dt$$

où ν et α sont des réels strictement positifs, et $m \in \mathbb{R}$.

Remarque. Le processus $(Z_t^H)_{t \geq 0}$ est appelé processus d'Orstein Uhlenbeck fractionnaire.

Plus précisément, les auteurs définissent le modèle de volatilité rugueuse (*Rough Fractional Stochastic Volatility model (RFSV)*) dans l'intervalle $[0, T]$ comme :

$$\sigma_t = \exp(Z_t^H), t \in [0, T]$$

où la valeur de H est de l'ordre de 0.1.

Le processus de log-prix $(Y_t)_{t \geq 0}$ satisfait donc l'EDS suivante :

$$dY_t = \mu_t dt + \sigma_t dB_t$$

où B est un mouvement brownien standard, et $(\mu_t)_{t \geq 0} \in \mathbb{H}_{loc}^1$.

Remarque. Les auteurs se concentrent sur le processus de log-prix plutôt que le processus de prix S (formellement suivant une dynamique de la forme $dS_t = \mu_t S_t dt + \sigma_t S_t dB_t$) afin d'y estimer plus facilement la volatilité (intégrée).

Dans la suite de ce projet, nous nous intéressons à l'estimation de ce paramètre de Hurst sur une série de données mises à disposition.

4 Étude statistique et estimations

4.1 Présentation des données

Durant la totalité du projet nous avons entraîné nos modèles en utilisant trois bases de données différentes :

- Les données journalières de prix du S&P500 sur une période de 10 ans de 3000 valeurs.
- Les données de volatilité journalière du S&P500 fournies par le Oxford Man Institute de 120 000 valeurs.
- Les données de log-prix et de volatilité simulées par ordinateur, suivant une dynamique proche de celle du modèle de [8].

La base de données simulées joue un rôle majeur dans notre étude car elle nous permet de calibrer les différents estimateurs proposés, et permet de rendre compte de résultats notables que l'on cherche à reproduire avec les bases de données réelles.

4.1.1 Quasi-gaussianité des $\log(\sigma_{t+1}) - \log(\sigma_t)$

Nous avons simulé des processus de log-prix $(Y_t)_{t \geq 0}$ satisfaisant l'EDS suivante :

$$dY_t = \sigma_t^H dB_t, Y_0 = 0$$

où B est un mouvement brownien, et σ^H est le processus de volatilité valant :

$$\sigma_t^H = e^{W_t^H}$$

où W^H est un mouvement brownien fractionnaire d'indice de Hurst $H \in (0, 1)$.

Par la suite, nous nous sommes intéressés à la distribution des processus $(\log(\sigma_{t+1}) - \log(\sigma_t))_{t \geq 0}$. Les figures 3 et 4 rendent compte du caractère quasi-gaussien de ces incréments.




FIGURE 3 – Histogramme des valeurs de $\log(\sigma_{t+1}) - \log(\sigma_t)$ pour $H = 0.7$ et $t \in [0, T]$




FIGURE 4 – Histogramme des valeurs de $\log(\sigma_{t+1}) - \log(\sigma_t)$ pour $H = 0.1$ et $t \in [0, T]$

Ce caractère quasi-gaussien permet à Mathieu Rosenbaum et al. [8] de présupposer que le processus de volatilité possède une forme similaire.

Les différents histogrammes avec les données réelles 5 rendent bien compte du même phénomène.




FIGURE 5 – Histogramme des valeurs de $\log(\sigma_{t+1}) - \log(\sigma_t)$ pour des données réelles




FIGURE 6 – Dynamique du processus de volatilité simulé au coefficient de Hurst $H = 0.1$.




FIGURE 7 – Dynamique du processus de volatilité simulé au coefficient de Hurst $H = 0.3$.

4.1.2 Processus de volatilité

Par ailleurs, il nous semble intéressant, dans une approche préliminaire, de présenter la dynamique de processus de volatilité simulé 6 7 dans le cas où le paramètre de Hurst est proche de 0.1 avec la dynamique du processus de volatilité de la base de données d'Oxford 8 afin de rendre compte de la pertinence de considérer un modèle de volatilité rugueuse.

De manière purement descriptive, il semblerait que le modèle de volatilité rugueuse avec paramètre de Hurst de l'ordre de 0.1 ressemble particulièrement au processus de volatilité de la base de données d'Oxford.

4.2 Estimation de H par la méthode [15]

4.2.1 Présentation du modèle

Dans la partie ci-dessous, nous présentons la méthode d'estimation par ondelettes du paramètre de Hurst dans des modèles de volatilité stochastique. Cette méthode se base sur l'article de 2006 de Mathieu Rosenbaum *Estimation of the volatility persistence in a discretely observed diffusion model*[15].




FIGURE 8 – Dynamique de la volatilité en fonction du temps

Dans cet article, l'auteur considère un modèle de diffusion de la forme

$$dY_t^1 = \sigma_t dB_t$$

où B est un mouvement brownien standard et σ est un processus défini par :

$$\sigma_t = \phi\left(\int_0^t a(u) dW_t^H\right)$$

où W^H est un mouvement brownien fractionnaire, a et ϕ deux fonctions dont les régularités sont présentées dans l'article.

L'article présente un estimateur du paramètre de Hurst dans le cas où $H > \frac{1}{2}$, cependant, dans le cadre de notre étude des modèles de volatilité rugueuse, il nous a semblé intéressant d'essayer d'appliquer cet estimateur en considérant des valeurs de H inférieures à $\frac{1}{2}$.

Dans cet article, l'auteur postule que l'on observe les valeurs de X de manière discontinues, *ie.* nous observons $Y_{\frac{i}{n}}$, $\forall i \in \{1, \dots, nT\}$, où $T > 0$.

Afin d'estimer H , l'auteur considère une base d'ondelettes $\psi_{j,k}$, définies de la manière suivante :

Soit ψ l'ondelette mère, on définit les ondelettes filles par[4] :

$$\psi_{j,k}(x) := 2^{\frac{j}{2}} \psi(2^j x - k)$$

On pose alors $d_{j,k} := \int_{\frac{k}{2^j}}^{\frac{k+T}{2^j}} \psi_{j,k}(s) \sigma_s^2 ds$, ainsi que les niveaux d'énergies $Q_j := \sum_k d_{j,k}^2$

En utilisant la propriété d'échelle, nous nous attendons à ce que

$$\frac{Q_{j+1}}{Q_j} = 2^{-2H} + o(1)$$

pour de grandes valeurs de j , ce qui nous donnerait la valeur de H .

4.2.2 Mise en place de l'algorithme

Rappelons que l'on observe uniquement les valeurs de Y de manière discontinues sur un intervalle de temps $[0, T]$. Afin de simplifier les calculs nous supposons jusqu'à la fin que

1. Y peut être perçu comme le logarithme d'un processus de prix

$n = 2^N$.

Définissons dans un premier temps quelques grandeurs.

$$z_i^n := n(Y_{\frac{i+1}{n}} - Y_{\frac{i}{n}})$$

On peut alors obtenir un premier estimateur de $d_{j,k}$ de la forme

$$\tilde{d}_{j,k} := \sum_{l=0}^{T2^{N-j}-1} z_{k2^{N-j+l}}^n \int_{\frac{k}{2^j} + \frac{l}{2^N}}^{\frac{k}{2^j} + \frac{l+1}{2^N}} \psi_{j,k}(t) dt$$

que l'on va débiaiser avec

$$\tilde{\nu}_{j,k} := n^2 \sum_{l=0}^{T2^{N-j}-1} \left(\int_{\frac{k}{2^j} + \frac{l}{2^N}}^{\frac{k}{2^j} + \frac{l+1}{2^N}} \psi_{j,k}(t) dt \right)^2 \widehat{a_{j,k,l}^2}$$

où $\widehat{a_{j,k,l}^2}$ est défini par

$$\widehat{a_{j,k,l}^2} := \left(\frac{\sqrt{2}}{h_n} \sum_{p=1}^{h_n} (z_{k2^{N-j+l+p}}^n)^2 \right)^2$$

avec $h_n := \lfloor n^{\frac{1}{2}} \rfloor$ Afin de finalement estimer $d_{j,k}^2$ par

$$\widehat{d_{j,k}^2} \approx \tilde{d}_{j,k}^2 - \tilde{\nu}_{j,k}$$

Pour finir, en notant

$$\hat{Q}_j^n := \sum_k \widehat{d_{j,k}^2}$$

On obtient notre estimateur final pour H , c'est-à-dire

$$H_{n,j} := -\frac{1}{2} \log_2 \left(\frac{\hat{Q}_{j+1}^n}{\hat{Q}_j^n} \right)$$

Remarque. La résolution optimale J_n^* de l'algorithme est définie par

$$J_n^* = \max\{j = 1, \dots, N, \hat{Q}_j^n \geq \frac{2^j}{n}\}$$

4.2.3 Présentation des données simulées :

Avant d'étudier l'efficacité de l'algorithme sur des données de prix réelles, il nous semblait essentiel de l'entraîner sur des données simulées.

Nous avons considéré ψ l'ondelette de Haar, $\phi(t) = e^t$, $a(t) = 1$, $N = 10$, $T = 3$. Nous avons donc simulé 3072 données de Y sur l'intervalle $[0, 3]$.

Nous avons estimé le processus de diffusion $Y_t = \int_0^t \sigma_s dB_s$ par sommes de Riemann, en calculant numériquement $\sum_{k=0}^{n-1} \sigma_{t_k^n} (B_{t_{k+1}^n} - B_{t_k^n})$, où $0 = t_0^n < \dots < t_{n-1}^n = t$.

Afin d'avoir une précision suffisante pour chaque valeur de $Y_{\frac{i}{n}}$, nous avons considéré en tout 196 608 (soit 3072×64) valeurs de B et σ . En d'autres termes, nous avons estimé la valeur de $X_{\frac{i+1}{n}} - X_{\frac{i}{n}}$ par $\sum_{k=0}^{n-1} \sigma_{t_k^n} (B_{t_{k+1}^n} - B_{t_k^n})$, où $\frac{i}{n} = t_0^{64} < \dots < t_{63}^{64} = \frac{i+1}{n}$.

De plus, nous avons estimé le processus à diffusion fractionnaire $\sigma_t = \phi(\int_0^t a(u) dW_t^H)$ de la même manière. Il nous fallait 196 608 valeurs de σ sur l'intervalle $[0, 3]$, et les avons estimé à l'aide de 12 582 912 (soit 196608×64) valeurs de W^H et de a .²

2. Voir l'appendice pour la présentation de quelques dynamiques simulées




FIGURE 9 – Histogramme de $\widehat{H}$ pour $H = 0.55$ sur données de prix simulées.




FIGURE 10 – Histogramme de $\widehat{H}$ pour $H = 0.6$ sur données de prix simulées.

4.2.4 Présentation des résultats sur données simulées de prix :

Nous avons entraîné l'estimateur pour diverses valeurs de H ³. Bien que la méthode d'estimation de l'article converge théoriquement uniquement pour des valeurs de $H > \frac{1}{2}$, nous avons cherché à l'entraîner aussi sur des valeurs de $H < \frac{1}{2}$ afin de voir si nous ne pouvions pas étendre le champ de convergence de l'algorithme au delà du seuil de $\frac{1}{2}$.

Afin que nos données soient plus représentatives, pour une même valeur théorique de H , nous avons entraîné l'algorithme sur de nombreuses trajectoires⁴. Il nous a semblé intéressant de présenter les histogrammes 9 10.

Nous remarquons que pour des valeurs de $H > \frac{1}{2}$, l'algorithme estime de manière relativement précise la valeur de H , comme l'indiquait l'article.

Malheureusement, il semblerait que lorsque la valeur de H devient inférieure à $\frac{1}{2}$, l'estimateur n'arrive plus à l'estimer convenablement et de manière consistente. L'étude de la moyenne des valeurs de H estimée est présentée dans le tableau 11 :

$H = 0.3$	$H = 0.4$	$H = 0.45$
$\widehat{H}_{moy} = 0.55$	$\widehat{H}_{moy} = 0.52$	$\widehat{H}_{moy} = 0.59$

FIGURE 11 – Moyenne des estimations de $H < \frac{1}{2}$ sur données de prix simulées.

4.2.5 Présentation des résultats sur données simulées de volatilité :

Supposons que nous puissions, non plus uniquement observer les valeurs discrètes de Y , mais directement les valeurs de σ . Dans ce cas, l'étape de débiaisage n'est plus utile, et en considérant l'ondelette de Haar, nous obtenons une estimation directe pour $d_{j,k}$.

En effet, nous obtenons

$$\widehat{d}_{j,k} = 2^{\frac{j}{2}} \left(\sigma^2 \left(\frac{T+k}{2^j} \right) - \sigma^2 \left(\frac{k}{2^j} \right) \right)$$

3. Toutes les simulations ont été réalisées en choisissant la résolution $j = 5$.

4. la taille des histogrammes est à corrélérer avec la nécessité de considérer une grande quantité de valeurs de brownien fractionnaire




FIGURE 12 – Histogramme de $\widehat{H}$ pour $H = 0.4$ sur données de volatilité simulées.




FIGURE 13 – Histogramme de $\widehat{H}$ pour $H = 0.43$ sur données de volatilités simulées.

On peut alors estimer H de la manière suivante :

$$\widehat{Q}_j^n := \sum_k \widehat{d}_{j,k}^2$$

$$H_{n,j} := -\frac{1}{2} \log_2 \left(\frac{\widehat{Q}_{j+1}^n}{\widehat{Q}_j^n} \right)$$

Via cette méthode, nous obtenons des estimations de H ⁵ plus précises pour des valeurs de H proches de $\frac{1}{2}$, et moins dispersées 12 13. Cette conclusion était attendue étant donné que lors de la simulation des valeurs de Y , ainsi que du débiaisage, nous perdons de l'information.

4.2.6 Mise en perspective des résultats

Les deux estimateurs présentés permettent d'estimer de manière consistente le paramètre de Hurst H lorsque celui-ci est supérieur à $\frac{1}{2}$, mais échouent à l'estimer lorsqu'il devient inférieur à ce seuil.

L'article dont l'estimateur est issu ayant été écrit avant l'étude intensive des modèles de volatilité rugueuse, il nous semble qu'un débiaisage différent soit nécessaire afin de pouvoir estimer le paramètre de Hurst dans des configurations où $H < \frac{1}{2}$.

4.3 Estimation de H par la méthode [8]

L'objectif de cette partie est de présenter la méthode d'estimation du paramètre de Hurst dans le modèle de volatilité rugueuse mise en place par Mathieu Rosenbaum, Jim Gatheral et Thibault Jaisson dans l'article de 2014 *Volatility is rough*[8]. Nous considérons le modèle détaillé dans la section 3.5.

Nous supposons la normalité, la stationnarité et l'indépendance des incréments de log-volatilité (via une étude statistique de la distribution incréments des log-volatilité). Sous ces hypothèses, les moments des incréments de log-volatilité suivent une loi d'échelle définie comme suit :

$$\mathbb{E}[|\log(\sigma_{t+\Delta}) - \log(\sigma_t)|^q] = K_q \Delta^{qH},$$

où nous considérons $K_q = \mathbb{E}[|Z|^q]$, avec $Z \sim \mathcal{N}(0, 1)$.

Cependant, deux problèmes se posent :

5. Toutes les simulations ont été réalisées en choisissant la résolution $j = 5$.

1. Nous n'observons pas directement σ_t
2. Nous ne connaissons pas précisément la valeur de $\mathbb{E}[|\log(\sigma_{t+\Delta}) - \log(\sigma_t)|^q]$

Afin de pallier ces problèmes, les auteurs proposent deux estimateurs :

1. Au lieu de construire directement un estimateur de la volatilité σ_t , nous considérons une estimation de la volatilité intégrée sur une fenêtre glissante de taille $2h$: $\tilde{\sigma}_{t,h} := \frac{1}{2h} \int_{t-h}^{t+h} \sigma_s^2 ds$. Pour ce faire, et grâce aux résultats (3) et (4), nous obtenons que $\int_{t-h}^{t+h} \sigma_s^2 ds = \lim_{\Delta_n \rightarrow 0} \sum_{k=0}^{(t/h)} (Y_{t_k^n} - Y_{t_{k-1}^n})^2$ où Δ_n est le pas de la subdivision $t-h = t_0^n < t_1^n < \dots < t_n^n = t+h$. Nous pouvons donc considérer comme estimateur consistant de la volatilité intégrée $\frac{1}{2h} \sum_{k=0}^n (Y_{t_k^n} - Y_{t_{k-1}^n})^2$ ⁶
2. Au lieu de considérer $\mathbb{E}[|\log(\sigma_{t+\Delta}) - \log(\sigma_t)|^q]$, nous considérons l'estimateur empirique, que nous définissons par :

$$m(q, \Delta) := \frac{1}{N} \sum_{k=1}^N |\log(\sigma_{k\Delta}) - \log(\sigma_{(k-1)\Delta})|^q,$$

où $N = \lfloor \frac{t}{\Delta} \rfloor$.

Par les considérations d'indépendance et de stationnarité des incréments de log-volatilité, cet estimateur est consistant et converge vers la valeur souhaitée lorsque le pas Δ tend vers 0.

4.3.1 Mise en place expérimentale

Première régression : Tout d'abord, nous réalisons la régression linéaire de $\log(m(q, \Delta))$ contre $\log(\Delta)$ pour plusieurs valeurs de q différentes. Nous obtenons, en notant ζ_q le coefficient directeur obtenu par la régression (on identifie le coefficient à sa valeur donnée par l'estimation), et en notant C_q l'ordonnée à l'origine, l'expression suivante :

$$\log(m(q, \Delta)) = C_q + \zeta_q \log(\Delta)$$

Soit

$$m(q, \Delta) = \tilde{C}_q \Delta^{\zeta_q}$$

Deuxième régression : Afin d'affiner la forme de $m(q, \Delta)$, nous régressons ζ_q contre q , et obtenons alors $\zeta_q = Hq$.

Conclusion des estimations : Finalement nous obtenons le résultat espéré et identifions H :

$$m(q, \Delta) = \tilde{C}_q \Delta^{qH}$$

Et en faisant tendre le pas Δ vers 0 nous obtenons bien $\mathbb{E}[|\log(\sigma_\Delta) - \log(\sigma_0)|^q] \approx \tilde{C}_q \Delta^{qH}$

4.3.2 Présentation des résultats sur des données simulées de volatilité

Afin d'évaluer la performance de notre estimateur, nous avons, dans un premier temps, simulé des processus de volatilité avec différents paramètres de H (0.1, 0.3, 0.5, 0.7) et avons estimé le paramètre de H correspondant avec notre algorithme afin de s'assurer de sa validité. Voici à quoi ressemble les différents processus simulés 1415 :

6. Nous remarquons que pour une fenêtre h tendant vers 0, la volatilité intégrée tend vers σ_t .




FIGURE 14 – Dynamique du processus de volatilité simulé au coefficient de Hurst $H = 0.5$.




FIGURE 15 – Dynamique du processus de volatilité simulé au coefficient de Hurst $H = 0.7$.

L'objectif était de pouvoir retomber via notre algorithme sur les mêmes valeurs de H . Les résultats obtenus sont les suivants 16 :

H choisi pour simulation	0.1	0.3	0.5	0.7
H estimé	0.0985	0.3020	0.4962	0.6989
R^2	1.000	1.000	1.000	1.000

FIGURE 16 – Estimation du paramètre H associé pour différentes données simulées de volatilité

Ainsi, notre algorithme semble nous permettre de retomber avec une assez bonne précision sur les valeurs de H choisies pour la simulation. De plus les estimations sont consistantes, en témoigne les $R^2 = 1$.

4.3.3 Présentation des résultats sur des données réelles de volatilité intégrée (base Oxford)

Pour poursuivre notre démarche scientifique, nous avons ensuite choisi d'essayer nos algorithmes d'estimation sur les données utilisées par les auteurs lors de la rédaction de leur article de 2014. Nous avons donc estimé H selon la méthode développée au dessus sur les données publiées par l'institut de recherche en mathématiques financières d'Oxford (Oxford MAN Institute) de volatilité réalisée journalière calculée sur des données S&P intra-day. Nous vous présentons les résultats obtenus ci-dessous 17.




FIGURE 17 – Régression linéaire de $\log(m(q, \Delta))$ contre $\log(\Delta)$ pour plusieurs valeurs de q

Coefficient de Hurst estimé : 0.0997 ($R^2 = 0.999$).

Nous retrouvons le même résultat que dans l'article, soit un H proche de 0.1. Nous remarquons




FIGURE 18 – Régression linéaire de ζ_q contre q

que la loi d'échelle est parfaitement vérifiée pour un coefficient H très petit, ce qui confirme la rugosité de la volatilité.

4.3.4 Présentation des résultats sur des données réelles de prix

Après avoir validé notre algorithme sur les données simulées et celles d'Oxford, on tente ici de l'appliquer sur des données réelles de prix journalières, en l'occurrence l'indice boursier du S&P 500. Il nous a paru intéressant, dans un premier temps, de comparer le comportement du paramètre H estimé dépendamment de la fenêtre h utilisée pour le calcul de proxy de la volatilité :

Longueur de la fenêtre h choisie	2	4	10	50	200
H estimé	0.0462	0.1159	0.2721	0.6165	0.6378
R^2	0.996	0.999	0.998	0.997	0.990

FIGURE 19 – Estimation du paramètre H pour différentes fenêtres h

Les résultats obtenus nous paraissent satisfaisants, nous pouvons remarquer que le paramètre H semble être croissant en la fenêtre. De plus, l'estimation est consistante car les R^2 est proche de 1.

Par ailleurs, on peut faire l'hypothèse que la croissance du paramètre de Hurst en fonction de la longueur de la fenêtre h est liée au fait que l'augmentation de cette dernière, adoucissant la "rugosité" de la volatilité réalisée approximée, mène à un paramètre de Hurst plus important. On remarque aussi que la valeur de H estimée semble atteindre un point de convergence autour de 0.6 lorsque nous la longueur de la fenêtre dépasse 50.

Pour finir cette partie estimation, nous n'utilisons plus ici le proxy présenté au début de la partie 4.4 : $\frac{1}{2h} \sum_{k=0}^n (Y_{t_k^n} - Y_{t_{k-1}^n})^2$. Nous avons trouvé intéressant d'observer la valeur du paramètre de Hurst estimé pour différents proxys de volatilité présentés en appendice :

- le modèle de Parkinson (1976) 6.4.1 : contrairement à la volatilité réalisée, qui semble pouvoir cacher de fortes variations journalières, ce modèle s'intéresse aux extremums journaliers afin de lever ce potentiel effet de masque :

$$\sigma_{P,t} = 0.361(\log(H_t) - \log(L_t))^2$$

- le modèle de Garman-Klass (1980) 6.4.2 : ce modèle précise la formule développée par Parkinson en prenant en compte les prix d'ouverture, de clôture, ainsi que les extremums journaliers :

$$\sigma_{GK,t} = 0.5[\log(H_t) - \log(D_t)]^2 - (2\log 2 - 1)[\log(O_t) - \log(C_t)]^2$$

- le modèle de Rogers-Satchell-Yoon (1991) 6.4.3 : contrairement aux modèles précédents qui considèrent le drift η nul, Rogers, Satchell et Yoon établissent un estimateur qui permet de gérer des drift η non nul mais également qui prenne en compte les prix caractéristiques d'une journée de trading (H_t, L_t, O_t, C_t) :

$$\sigma_{RSY,t} = (\log(H_t) - \log(O_t))(\log(H_t) - \log(C_t)) + (\log(L_t) - \log(O_t))(\log(L_t) - \log(C_t))$$

Voici les résultats obtenus pour les différents proxys de volatilité présentés ci-dessus :

Proxy de volatilité	$\sigma_{P,t}$	$\sigma_{GK,t}$	$\sigma_{RSY,t}$
H estimé	0.2039	0.2069	0.1797
R^2	1.000	1.000	1.000

FIGURE 20 – Estimation du paramètre H pour les différents proxys de volatilité présentés

Ici encore, les résultats obtenus pour les différents proxys sont satisfaisants, en témoigne la valeur des H estimés ainsi que les R^2 associés proche de 1.

5 Conclusion

Durant ce projet, nous avons estimé le paramètre de Hurst pour des modèles de volatilité rugueuse via différentes méthodes et en utilisant différentes data afin de rendre compte de la rugosité du processus de volatilité.

Dans un premier temps, nous avons étudié l'article [15]. Bien que l'article propose un estimateur de H consistant pour des valeurs de $H > \frac{1}{2}$, il nous a semblé intéressant d'étudier empiriquement la convergence de l'estimateur pour diverses valeurs de H sur des données de volatilité et de prix simulées. Les résultats semblent cohérents avec l'article, dans le sens où, pour des valeurs de H supérieures à $\frac{1}{2}$ l'estimateur estime bien la valeur théorique, mais pour des valeurs proches de $\frac{1}{2}$, et inférieures, malheureusement l'estimateur ne converge plus, laissant penser à une nécessité de modifier l'estimateur afin de prendre plus en compte le caractère rugueux des processus.

Dans un second temps, nous nous sommes intéressés à l'estimateur du paramètre de Hurst développé dans l'article [8]. Après l'avoir étudié de manière théorique, nous l'avons entraîné sur des données simulées de prix, puis sur des données de volatilité journalières, et enfin sur des données de prix journalières. Les estimations sont cohérentes avec celles réalisées dans l'article.

Pour conclure, nous avons pu, durant ce projet, étudier d'un point de vue théorique et pratique, les modèles de volatilité rugueuse.

6 Appendice

6.1 Cadre mathématique

Durant tout le mémoire nous considérons l'espace probabilisé filtré suivant : $(\Omega, \mathcal{F}, \mathbb{P}, (\mathcal{F}_t)_{t \geq 0})$. Pour tout développement des outils probabilistes présentés dans cette partie, veuillez vous référer à [11] et [12].

Définition 6.1 (Mouvement brownien). *Nous définissons le $(\mathcal{F}_t)_{t \geq 0}$ -mouvement brownien $(B_t)_{t \geq 0}$ comme l'unique processus gaussien à trajectoire continues, de moyenne nulle et de fonction de variance-covariance $\gamma(t, s) = t \wedge s$.*

Définition 6.2 (Mouvement brownien fractionnaire). *Nous définissons le $(\mathcal{F}_t)_{t \geq 0}$ -mouvement brownien fractionnaire $(W_t^H)_{t \geq 0}$, d'indice de Hurst $H \in (0, 1)$ comme l'unique processus gaussien à trajectoire continues, de moyenne nulle et de fonction de variance-covariance $\gamma^H(t, s) = \frac{1}{2}(|s|^{2H} + |t|^{2H} - |t - s|^{2H})$.*

Remarque. Lorsque $H = \frac{1}{2}$, le mouvement brownien et le mouvement brownien fractionnaire coïncident.

Proposition 6.1. *Le mouvement Brownien fractionnaire est à accroissements stationnaires dans le sens où pour tout $t, \delta \geq 0$*

$$W_{t+\delta}^H - W_t^H \stackrel{\mathcal{L}}{=} W_\delta^H.$$

Il vérifie la propriété d'auto-similarité suivante :

$$\forall a > 0, t \geq 0, \quad W_{at}^H \stackrel{\mathcal{L}}{=} a^H W_t^H.$$

De plus, pour tout $0 < h < H$, W^H est presque sûrement h -hölderien.

Définition 6.3 (Processus progressivement mesurable). *Soit $\phi : (\Omega \times \mathbb{R}) \rightarrow \mathbb{R}$ un processus. ϕ est progressivement mesurable si :*

$\forall t > 0$, le processus

$$\phi : \left\{ \begin{array}{ll} ((\Omega, \mathcal{F}_t) \times ([0, t], \mathcal{B}([0, t]))) & \longrightarrow \mathbb{R} \\ (\omega, s) & \longmapsto \phi(\omega, s) \end{array} \right.$$

est mesurable.

Définition 6.4 (Espace $\mathbb{H}^2$). *Soit ϕ un processus. On dit que $\phi \in \mathbb{H}^2$ lorsqu'il est progressivement mesurable et que :*

$$\forall t > 0, \mathbb{E}[\int_0^t |\phi_s|^2 ds] < \infty$$

Dans ce cas, nous avons la formule d'isométrie suivante :

$$\mathbb{E}[\int_0^t |\phi_s|^2 ds] = \mathbb{E}[(\int_0^t \phi_s dB_s)^2] \quad (1)$$

Définition 6.5 (Espaces $\mathbb{H}_{loc}^p$). *Soit ϕ un processus. On dit que $\phi \in \mathbb{H}_{loc}^p$ lorsqu'il est progressivement mesurable et que :*

$$\forall t > 0, \int_0^t |\phi_s|^p ds < \infty$$

presque partout, pour $p \geq 1$.

Remarque. Lorsque $\phi \in \mathbb{H}^2$, alors le processus $t \rightarrow \int_0^t \phi_s dB_s$ est une martingale centrée, de variance $\int_0^t \phi_s^2 ds$.

Lorsque $\phi \in \mathbb{H}_{loc}^2$, alors le processus $t \rightarrow \int_0^t \phi_s dB_s$ est une martingale locale.

Définition 6.6. Soit μ et σ deux processus progressivement mesurables tels que

$$\forall t > 0, \int_0^t |\mu_s| ds < \infty$$

$$\forall t > 0, \int_0^t |\sigma_s|^2 ds < \infty$$

presque partout.

On dit que le processus X satisfait l'équation :

$$dX_t = \mu_t dt + \sigma_t dB_t, X(0) = X_0$$

lorsque

$$X_t = X_0 + \int_0^t \mu_s ds + \int_0^t \sigma_s dB_s$$

Le processus X est appelé processus d'Itô.

Définition 6.7 (Variation quadratique). Soit X un processus d'Itô. On définit alors sa variation quadratique $\langle X \rangle_t$ par :

$$\langle X \rangle_t = \int_0^t \sigma_s^2 ds$$

Remarque. De manière générale, la variation quadratique d'un processus X est définie par :

$$\langle X \rangle_t := \lim_{\Delta_n \rightarrow 0} \sum_{(t_k^n)} (X_{t_k^n} - X_{t_{k-1}^n})^2$$

où Δ_n est le pas de la subdivision $0 = t_0^n < t_1^n < \dots < t_n^n = t$

Théorème 6.1 (Formule d'Itô). Soit $f \in \mathcal{C}^{1,2}(\mathbb{R}^+ \times \mathbb{R})$ et soit X un processus d'Itô. Alors nous avons la formule suivante :

$$f(t, X_t) = f(0, X_0) + \int_0^t \partial_t f(s, X_s) ds + \int_0^t \partial_x f(s, X_s) \mu_s ds + \int_0^t \partial_x f(s, X_s) \sigma_s dB_s + \frac{1}{2} \int_0^t \partial_{xx} f(s, X_s) \sigma_s^2 ds$$

Définition 6.8 (Équation différentielle stochastique). Un processus X est solution d'une équation différentielle stochastique (EDS) si X résout

$$dX_t = \mu(t, X_t) dt + \sigma(t, X_t) dB_t, X(0) = X_0$$

Théorème 6.2 (Solution forte EDS). L'équation ci-dessus admet une unique solution si :

- les processus μ et σ sont mesurables
- $(\mu(t, X_t))_{t \geq 0} \in \mathbb{H}_{loc}^1, (\sigma(t, X_t))_{t \geq 0} \in \mathbb{H}_{loc}^2$
- $\exists K > 0$ tel que $|\mu(t, x) - \mu(t, y)| + |\sigma(t, x) - \sigma(t, y)| \leq K|x - y|, \forall (t, x, y) \in \mathbb{R}^+ \times \mathbb{R}^2$
- $\forall t > 0, \int_0^t \mu(s, 0)^2 ds + \int_0^t \sigma(s, 0)^2 ds < \infty$

6.2 Dynamiques de prix et de volatilité simulées




FIGURE 21 – Dynamique du processus σ pour $H = 0.3$.




FIGURE 22 – Dynamique du processus Y pour $H = 0.3$.

6.3 Histogramme de $\widehat{H}$ pour des valeurs de volatilité simulées dans le modèle[15]




FIGURE 23 – Histogramme de $\widehat{H}$ pour $H = 0.5$ sur données de volatilité simulées.




FIGURE 24 – Histogramme de $\widehat{H}$ pour $H = 0.8$ sur données de volatilité simulées.

6.4 Construction des proxy de volatilité

Après avoir donné en 2 les deux principales définitions de la volatilité, réalisée et implicite, nous détaillons ici différentes méthodes employées pour l'obtention des proxys de volatilité ainsi que le coefficient de Hurst. Nous avons pour cela utilisé les données de prix journalières du S&P 500 entre 2013 et 2023, et non des données intra-day contrairement aux calculs de volatilité faits sur la base de données d'Oxford.

Ainsi, nous aborderons dans un premier temps le modèle de Parkinson[13] (1976), puis celui de Garman-Klass[1] (1980), avant de finalement présenter celui de Rogers-Satchell-Yoon[14] (1991).

6.4.1 Modèle de Parkinson (1976)

Se basant sur les prix des cours de clôtures, la volatilité réalisée, aussi appelée historique, semble pouvoir cacher de fortes variations intervenant au cours d'une même séance. Ayant aperçu cette lacune, Parkinson introduit en 1980 une formule[13] prenant en compte ces extremums journaliers, permettant de lever cet effet de masque. Ce dernier s'intéresse davantage à la différence l entre le maximum et le minimum sur chaque intervalle de temps plutôt qu'à $X_i - \bar{X}$ pour estimer σ . Il propose alors $P(l,t)$ la probabilité que $\log(S_{max}) - \log(S_{min}) \leq l$:

$$P(l, t) = \sum_{n=1}^{\infty} (-1)^{n+1} n \left[\operatorname{erfc}\left(\frac{(n+1)l}{\sqrt{2}\sigma}\right) - 2\operatorname{erfc}\left(\frac{nl}{\sqrt{2}\sigma}\right) + \operatorname{erfc}\left(\frac{(n-1)l}{\sqrt{2}\sigma}\right) \right], \quad (2)$$

où $\operatorname{erfc}(x) = 1 - \operatorname{erf}(x)$, et $\operatorname{erf}(x)$ est la fonction d'erreur.

Ainsi Parkinson obtient de la formule des moments d'ordre p :

$$\mathbb{E}[l^p] = \frac{4}{\sqrt{\pi}} \Gamma\left(\frac{p+1}{2}\right) \left(1 - \frac{4}{2^p}\right) \zeta(p-1) (2\sigma)^{p/2}, \quad (3)$$

où p est un réel ≥ 1 , $\zeta(x)$ est la zeta fonction de Riemann. En particulier, nous avons $\mathbb{E}[l^2] = (4\ln(2))\sigma$, ce qui permet d'avoir :

$$\sigma = \frac{0.361}{n} \sum_{i=1}^n l_i^2. \quad (4)$$

Parkinson finit par comparer les variances respectives de σ_1 , la constante de diffusion obtenue par $X_i - \bar{X}$, et σ_2 , celle obtenue par les extremums :

$$\mathbb{E}[(\sigma_1 - \sigma)^2] = \frac{2\sigma^2}{N}, \quad (5)$$

$$\mathbb{E}[(\sigma_2 - \sigma)^2] = \frac{0.41\sigma^2}{N}, \quad (6)$$

où N représente le nombre d'observations.

Ainsi pour avoir la même variance, il faudrait 5 fois plus d'observations pour N_x : l'utilisation des extremums permet d'être bien plus sensible aux variations de σ .

Nous définissons alors ici le proxy de volatilité développé par Parkinson, donné comme suit :

$$\sigma_2 = \sigma_{P,t} = 0.361(\log(H_t) - \log(L_t))^2, \quad (7)$$

où H_t et L_t représentent respectivement la valeur maximale et minimale du prix sur l'intervalle t .

6.4.2 Modèle de Garman-Klass (1980)

Mark B. Garman et Michael J. Klass étendent la formule de Parkinson en proposant une estimation de la volatilité[1] en intégrant les prix d'ouverture, de clôture, ainsi que les extremums de la journée. Selon eux, ne considérer que les extremums impliquerait d'ignorer les effets joints entre ces derniers et la valeur de clôture. Leur modèle prend ainsi en compte l'activité des marchés aux moments de l'ouverture et de la clôture des sessions de trading, périodes pendant lesquelles les prix peuvent être particulièrement volatils.

Garman et Klass tentent de proposer le "meilleur" estimateur possible, au sens de celui avec la plus petite variance et sans biais.

Notons H_t le prix maximal atteint dans la journée t et L_t le prix minimal. Notons également O_t le prix d'ouverture et C_t le prix de fermeture.

Afin de comprendre comment ces derniers arrivent à formuler leur estimateur, il convient d'introduire la notion de "règles de décision", qui sont des fonctions $D(H_t, L_t, C_t)$ ne dépendant que H_t , L_t et C_t . Par symétrie de prix et de temps, ces règles de décision peuvent se réécrire comme suit :

$$D(H_t, L_t, C_t) = D(-H_t, -L_t, -C_t) \quad (8)$$

et

$$D(H_t, L_t, C_t) = D(H_t - C_t, L_t - C_t, -C_t). \quad (9)$$

De plus, par propriété d'invariance d'échelle, la règle de décision vaut :

$$D(\lambda H_t, \lambda L_t, \lambda C_t) = \lambda^2 D(H_t, L_t, C_t), \lambda > 0. \quad (10)$$

Garman and Klass développe aussi la propriété suivante : $D(H_t, L_t, C_t)$ doit être analytique, autrement dit elle est développable en série entière au voisinage de chacun de ses points. Ainsi ils redéfinissent la règle de décision :

$$D(H_t, L_t, C_t) = a_{200}H_t^2 + a_{020}D_t^2 + a_{002}C_t^2 + a_{110}H_tD_t + a_{101}H_tC_t - t + a_{011}D_tC_t. \quad (11)$$

Puis, par calcul et minimisation de cette quantité, comme cette dernière est sans biais (autrement dit elle équivaut à σ^2) et que le prix de fermeture n'est pas nécessairement égal au prix d'ouverture ils obtiennent finalement :

$$\sigma_{GK,t} = 0.5[\log(H_t) - \log(D_t)]^2 - (2\log 2 - 1)[\log(O_t) - \log(C_t)]^2. \quad (12)$$

6.4.3 Modèle de Rogers-Satchell-Yoon (1991)

Le modèle de Parkinson et celui de Garman-Class considèrent tout deux qu'il n'y a pas de drift η dans leur estimation de la volatilité. Toutefois, il nous apparait assez clairement que certains actifs peuvent avoir une tendance pendant une certaine période de temps. Dès lors, un meilleur estimateur prendrait en compte ce facteur.

Rogers, Satchell et Yoon proposent une troisième version d'estimateur de la volatilité[14], afin de tenter de résoudre certaines limites observées dans les estimateurs précédents. En effet, $\sigma_{GK,t}$ est biaisé lorsque le drift η est non nul. De plus en simulant des données, il apparait que la valeur numérique obtenue de la volatilité n'est pas aussi proche qu'elle ne devrait l'être de sa véritable valeur.

Ainsi, Rogers, Satchell et Yoon établissent un estimateur qui permet de gérer des drift η non nul mais également qui prenne en compte les prix caractéristiques d'une journée de trading (H_t, L_t, O_t, C_t) :

$$\sigma_{RSY,t}^2 = (\log(H_t) - \log(O_t))(\log(H_t) - \log(C_t)) + (\log(L_t) - \log(O_t))(\log(L_t) - \log(C_t)). \quad (13)$$

Références

- [1] Barbara BĘDOWSKA-SÓJKA et Agata KLIBER. “Information content of liquidity and volatility measures”. In : *Physica A : Statistical Mechanics and its Applications* 563 (2021), p. 125436.
- [2] Carsten CHONG et al. “Statistical inference for rough volatility : Central limit theorems”. In : *arXiv preprint arXiv :2210.01216* (2022).
- [3] Carsten H CHONG et al. “Statistical inference for rough volatility : Minimax theory”. In : *Available at SSRN 4236905* (2022).
- [4] Zbigniew CIESIELSKI, Gérard KERKYACHARIAN et Bernard ROYNETTE. “Quelques espaces fonctionnels associés à des processus gaussiens”. In : *Studia Mathematica* 107.2 (1993), p. 171-204.
- [5] Fabienne COMTE et Eric RENAULT. “Long memory in continuous-time stochastic volatility models”. In : *Mathematical finance* 8.4 (1998), p. 291-323.
- [6] Bruno DUPIRE et al. “Pricing with a smile”. In : *Risk* 7.1 (1994), p. 18-20.
- [7] Masaaki FUKASAWA. “Asymptotic analysis for stochastic volatility : martingale expansion”. In : *Finance and Stochastics* 15 (2011), p. 635-654.
- [8] Jim GATHERAL, Thibault JAISSON et Mathieu ROSENBAUM. “Volatility is rough”. In : *Commodities*. Chapman et Hall/CRC, 2022, p. 659-690.
- [9] Arnaud GLOTER et Marc HOFFMANN. “Estimation of the Hurst parameter from discrete noisy data”. In : *The Annals of Statistics* 35.5 (2007), p. 1947-1974.
- [10] John HULL et Alan WHITE. “The general Hull–White model and supercalibration”. In : *Financial Analysts Journal* 57.6 (2001), p. 34-43.
- [11] Damien LAMBERTON et Bernard LAPEYRE. *Introduction to stochastic calculus applied to finance*. Chapman et Hall/CRC, 2011.
- [12] Jean-François LE GALL. *Mouvement brownien, martingales et calcul stochastique*. T. 71. Springer, 2013.
- [13] Peter MOLNÁR. “High-low range in GARCH models of stock return volatility”. In : *Applied Economics* 48.51 (2016), p. 4977-4991.
- [14] MP PANDIKUMAR et al. “A Study on the Historical Volatility of Various Indices over a Period of Time in the Indian Stock Market with Reference to National Stock Exchange”. In : *Asian Journal of Research in Business Economics and Management* 4.2 (2014), p. 72-98.
- [15] Mathieu ROSENBAUM. “Estimation of the volatility persistence in a discretely observed diffusion model”. In : *Stochastic processes and their applications* 118.8 (2008), p. 1434-1462.